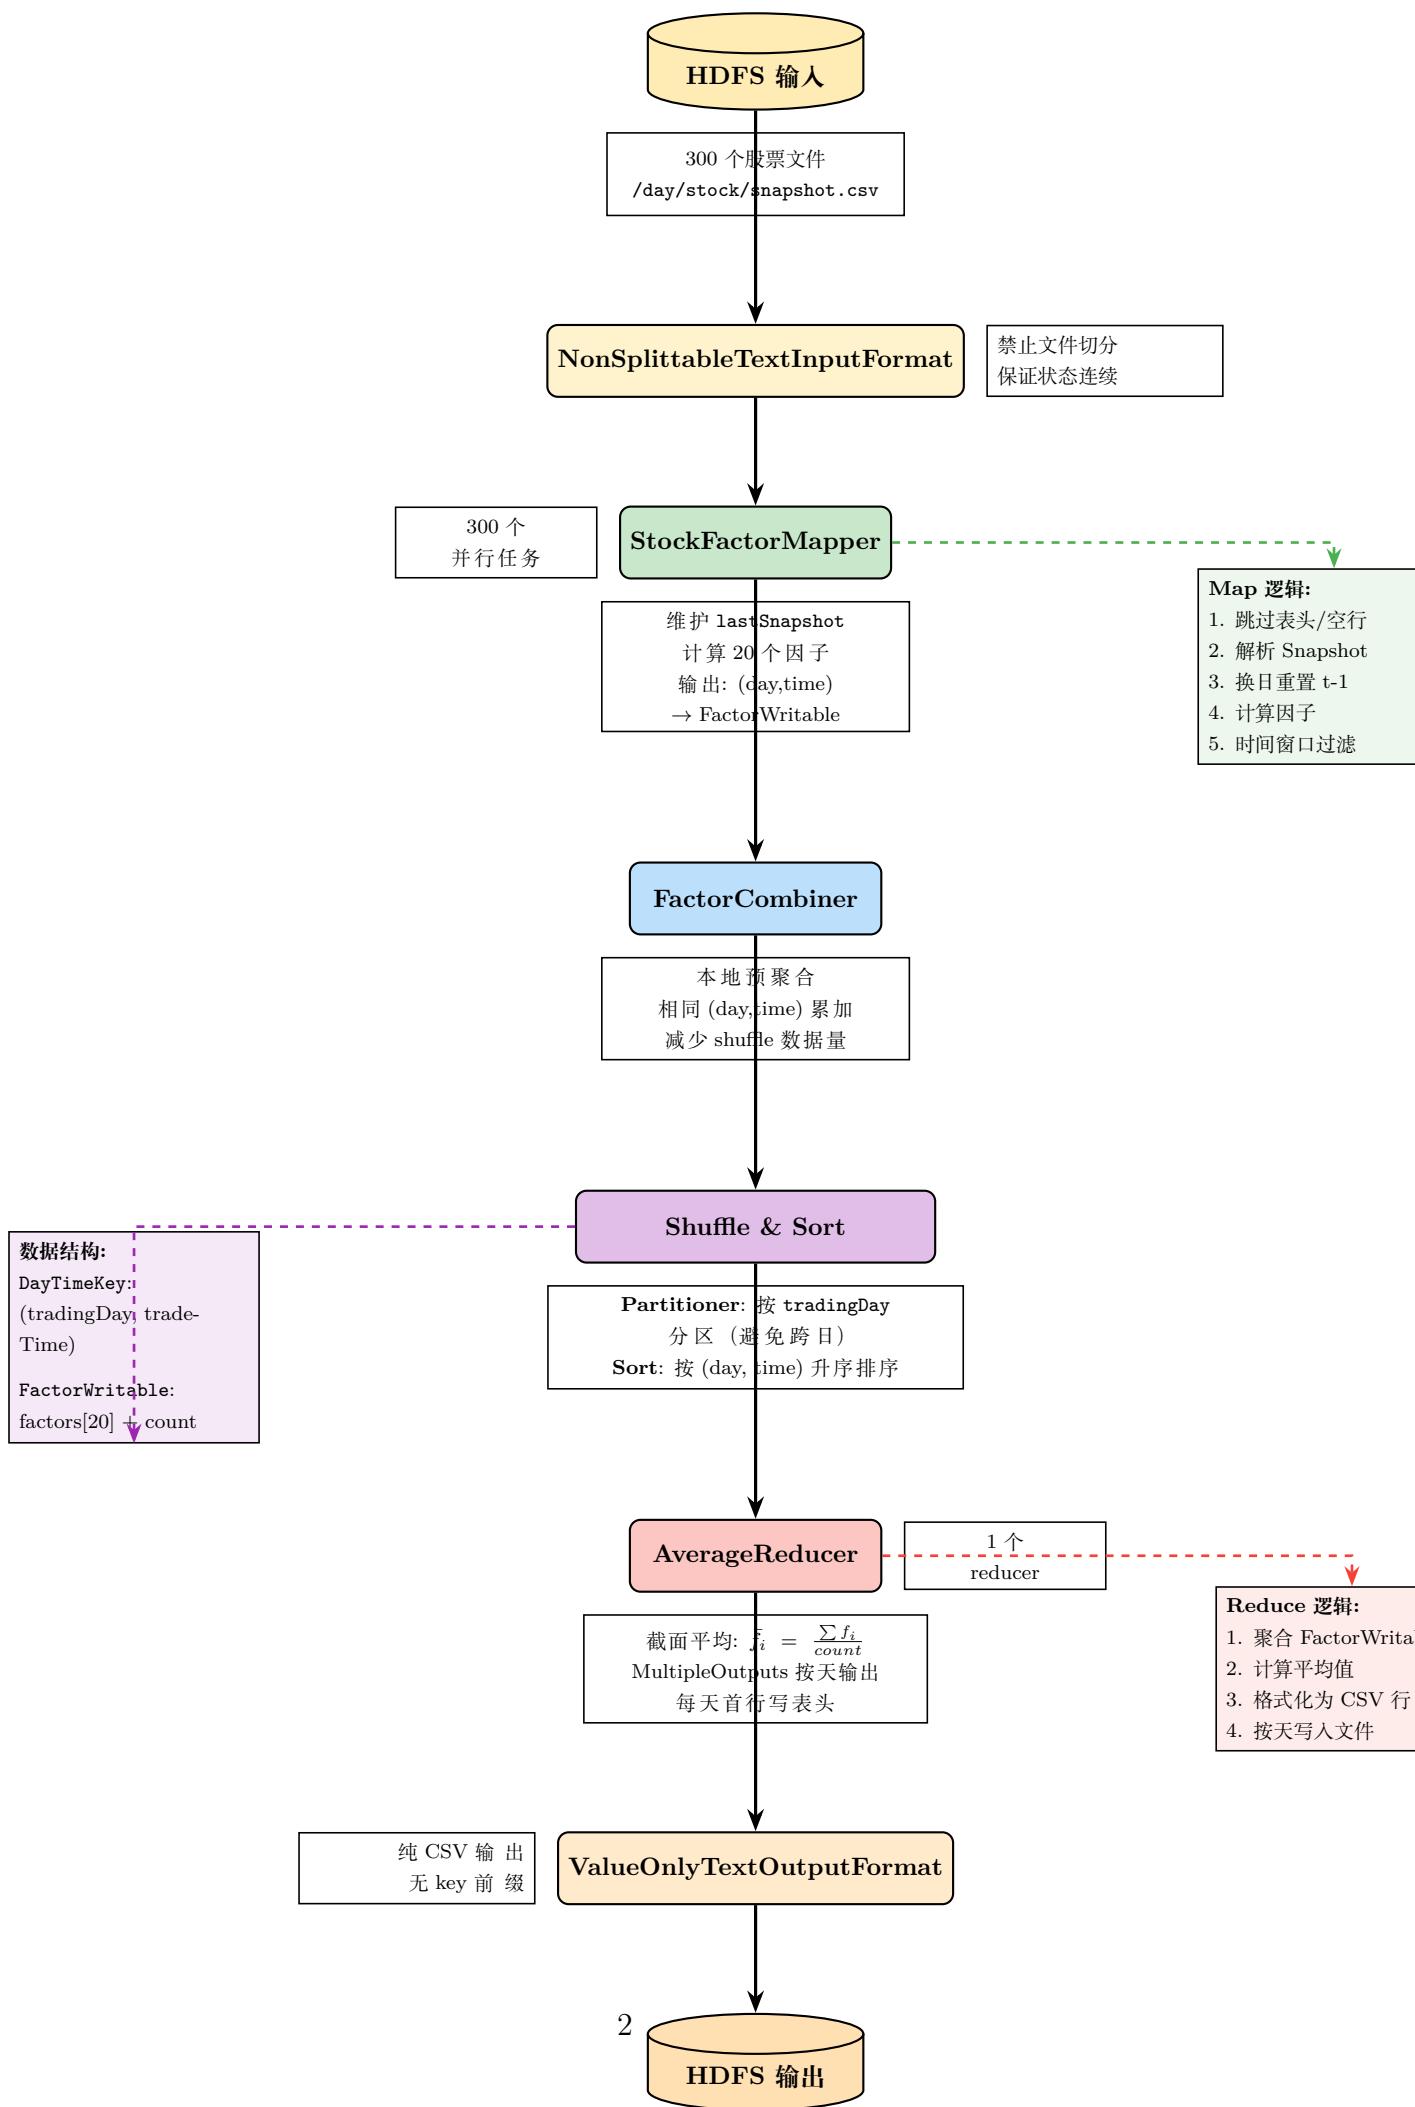


CSI300 因子计算 MapReduce 流水线

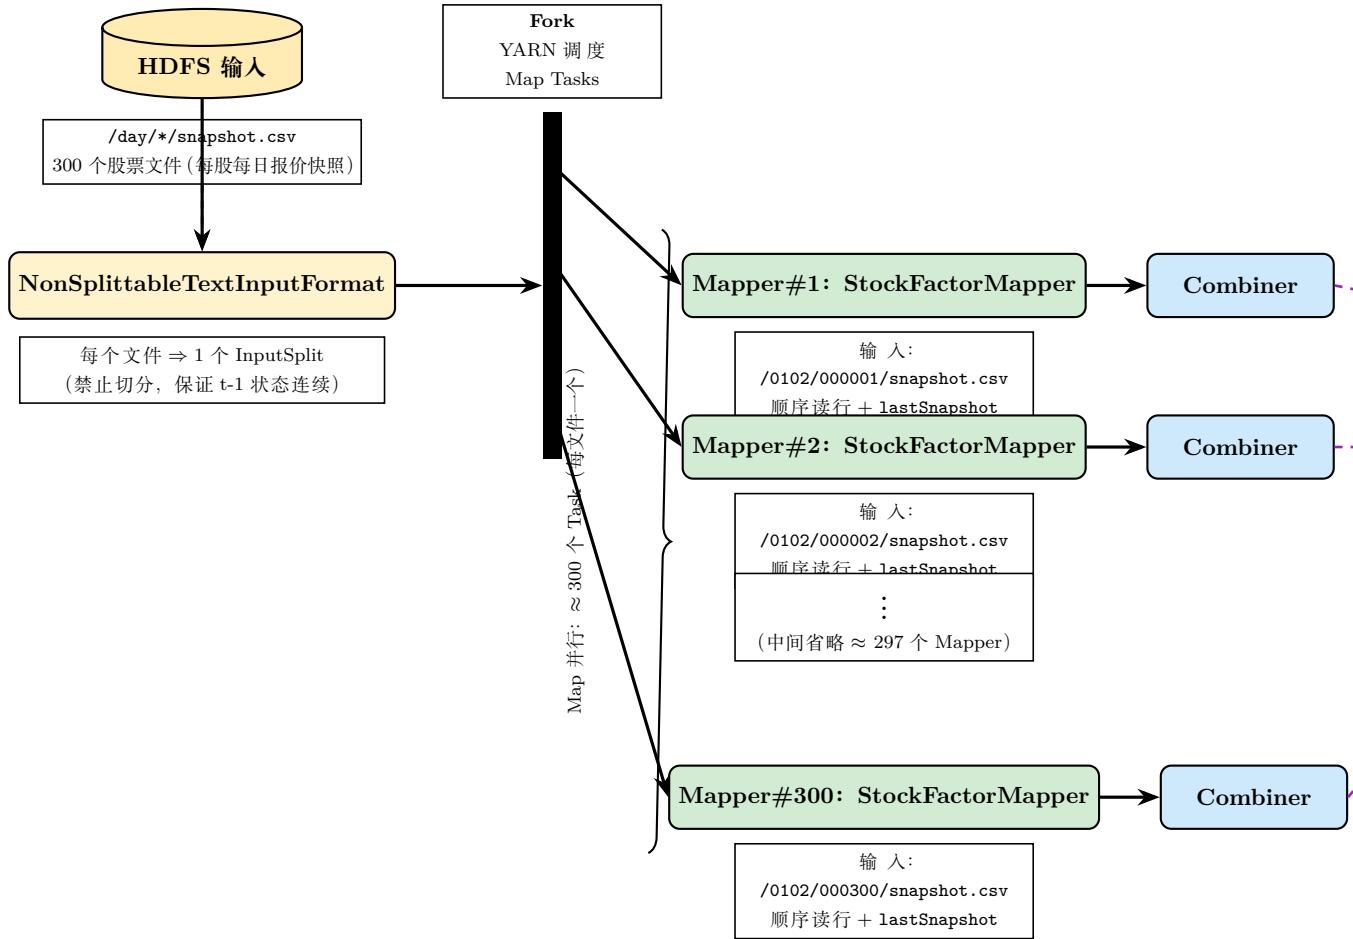
整体架构概览

本项目使用 Hadoop MapReduce 框架，对 CSI300 指数的 300 只股票的高频快照数据（3 秒频）计算 20 个量化因子，并在每个时刻对 300 只股票做截面平均。



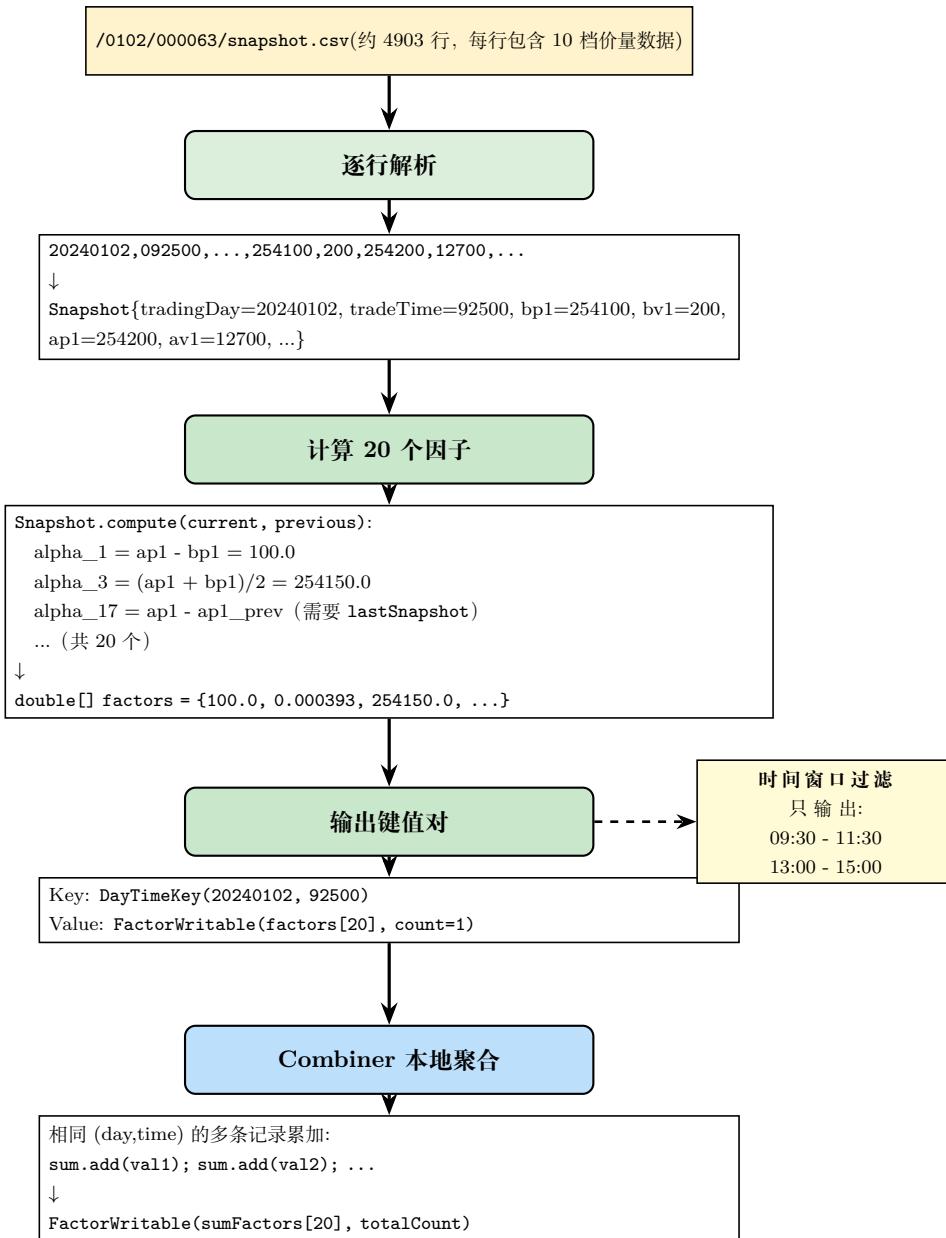
详细数据流示意

1. MapReduce 并行执行示意 (Fork/Join)



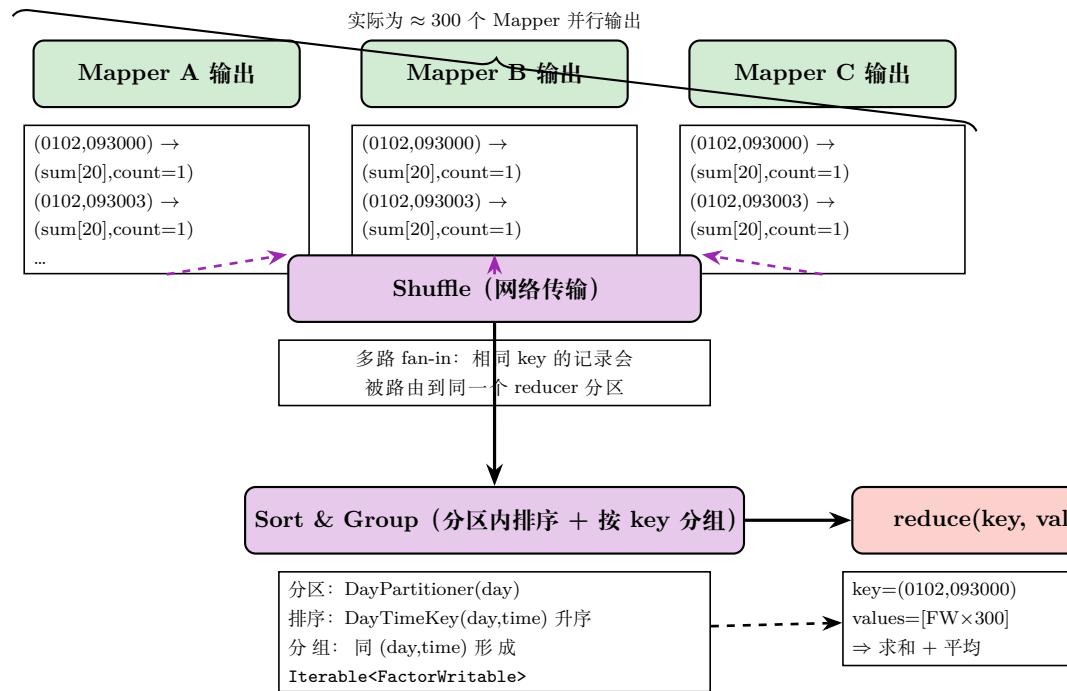
2. 单个 Mapper 的处理流程 (顺序读行 + 状态 t-1)

单个 Mapper 的处理流程 (以股票 000063 为例)



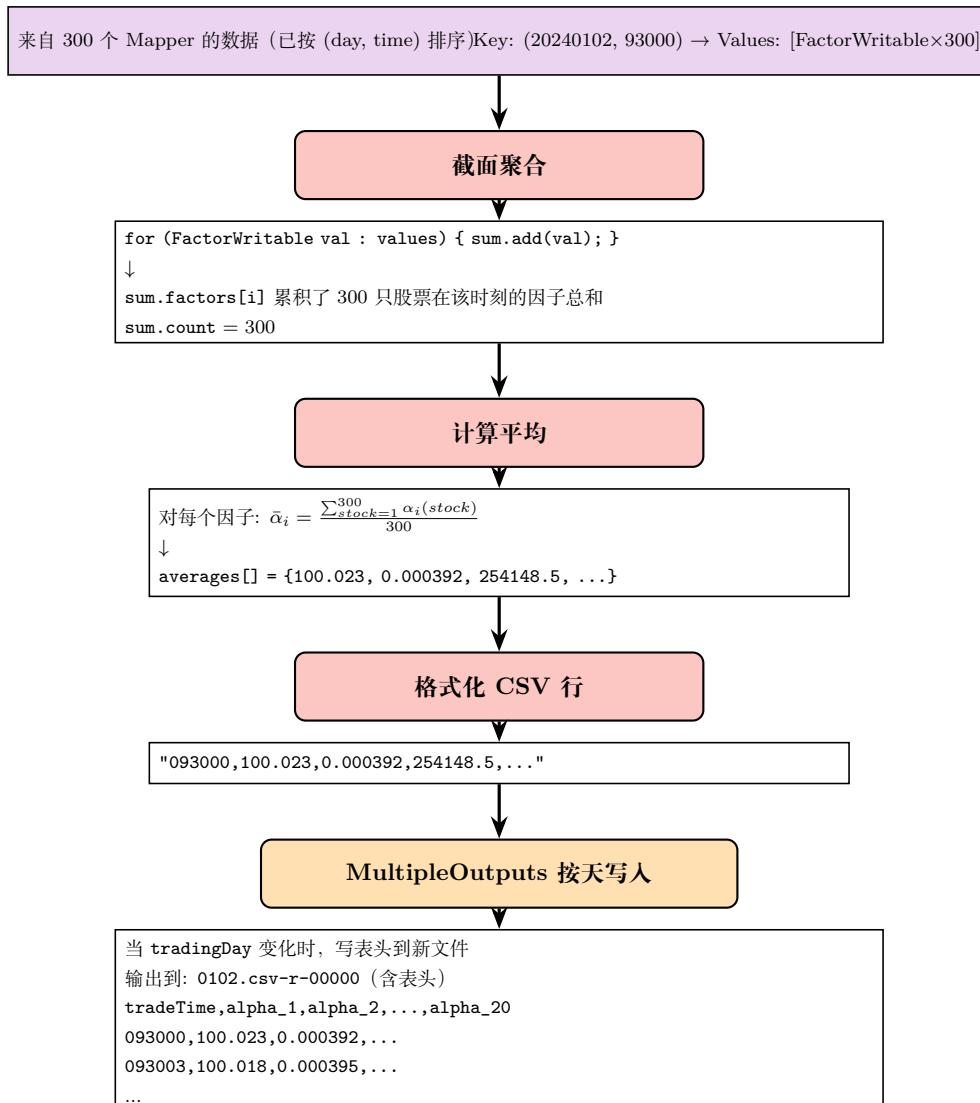
3. Shuffle/Sort: 按 (day,time) 分组 (Join 前的对齐)

示例: 3 个 Mapper (实际 ≈ 300) 在同一时刻对齐到同一个 reduce(key)



4. Reducer 聚合与输出 (Join: 300 股截面平均)

Reducer 聚合与输出流程



关键设计要点

1. 状态维护 (Mapper 中的 lastSnapshot)

因子 alpha_17, alpha_18, alpha_19 依赖上一时刻的数据：

$$\begin{aligned}\alpha_{17} &= ap1_t - ap1_{t-1} \\ \alpha_{18} &= \frac{1}{2}[(ap1_t + bp1_t) - (ap1_{t-1} + bp1_{t-1})] \\ \alpha_{19} &= \frac{\sum bv_t}{\sum av_t} - \frac{\sum bv_{t-1}}{\sum av_{t-1}}\end{aligned}$$

因此 Mapper 必须：

- 维护 lastSnapshot 变量
- 按时间顺序处理同一股票的所有记录
- 遇到换日时重置 lastSnapshot = null

2. 文件不切分 (NonSplittableTextInputFormat)

如果 Hadoop 将一个股票文件切成多个 split：

- Split1 的 Mapper 处理前半部分 ✓
- Split2 的 Mapper 处理后半部分 ✗ (无法获取 Split1 的最后一条作为 t-1)

解决方案：强制每个文件作为一个整体由单个 Mapper 处理。

3. 按天分区 (DayPartitioner)

DayPartitioner 只根据 tradingDay 计算分区号，确保：

- 同一天的所有数据进入同一个 Reducer
- 不同天的数据不会混算
- Reducer 可以安全地按天输出独立文件

4. 时间窗口过滤 (Mapper 中的 shouldEmit)

虽然原始数据包含全天的快照，但标准答案只要求输出交易时段：

- 上午： 09:30:00 - 11:30:00
- 下午： 13:00:00 - 15:00:00

注意：即使某条记录不在输出窗口，也要维护 lastSnapshot，因为 09:30:00 的 t-1 可能来自 09:29:57。

5. 数据流量统计（实际运行结果）

阶段	记录数/数据量
Map input records	1,470,900 行
Map output records	1,440,600 行 (过滤后)
Map output bytes	259 MB
Combine input/output	1,440,600 行
Shuffle bytes	263 MB
Reduce input groups	4,802 个 (day,time) 组合
Reduce input records	1,440,600 行
HDFS bytes written	1.76 MB (5 天 CSV)

6. 并行度

- **Mapper 数量:** 300 (等于输入文件数, 无法改变)
- **Combiner 实例:** 300 (每个 Mapper 后自动运行)
- **Reducer 数量:** 1 (可通过 `-Dfactor.reducer=N` 调整)

单 Reducer 的优点:

- 每个交易日只写一次表头
- 避免多个 Reducer 输出需要后续合并
- 对于 4802 个时间点, 单 Reducer 足够